

UNIVERSITÀ DEGLI STUDI DI SALERNO, DIPARTIMENTO DI
INFORMATICA


REINFORCEMENT LEARNING & LLM

Risolvere Sokoban.

Cinque agenti a confronto su un puzzle di
pianificazione PSPACE-completo: dove un
modello linguistico aiuta un agente di RL, e dove
lo peggiora.

Antonio Di Giorgio


Matr. 0522502003, Laurea Magistrale in Informatica, A.A. 2025-2026



Regole semplici, complessità **PSPACE**.

Spingere le casse sui bersagli si impara in un minuto.

Trovare la soluzione appartiene a una classe di complessità più alta di NP, e ogni spinta può chiudere la partita.



cassa contro due muri, stallo irreversibile

PSPACE

Complessità estrema

PSPACE-completo: una classe più alta di NP.



Mosse irreversibili

Una cassa nell'angolo è persa per sempre.



Reward sparsa

Nessun feedback prima della soluzione.

Un LLM può **aiutare** un agente di RL su un problema combinatorio, o finisce per **peggiorarlo**?

5

agenti a confronto

2

sistemi di gioco

100



episodi per fase

64

test unitari

La griglia diventa numeri.

CODIFICA DELLE CELLE

	0 muro		3 cassa
	1 pavimento		4 cassa a posto
	2 target		5 giocatore
	6 giocatore a posto		7 padding

OBSERVATION SPACE

`Box(0, 7, shape=(10,10))`

ACTION SPACE

`Discrete(4)`

su, giù, sinistra, destra

8x ambienti in parallelo via SubprocVecEnv

Cinque componenti.

Eventi rari, la penalità di passo e i bonus, più due termini di shaping densi, basati sulla distanza e pesati da λ .

OBIETTIVO

+10

Livello risolto

quando ogni cassa copre un bersaglio

-0.005

Penalità di step (ogni azione)

+1.0

Cassa su target (-1.0 se rimossa)

λ 0.3


Casse $\rightarrow$ target (Manhattan, Ungherese)

λ 0.1

Giocatore $\rightarrow$ cassa (cassa più vicina)

i due termini di shaping sono delta-based: contano solo la variazione tra un passo e il successivo

Una CNN, una memoria.



Cinque agenti.

RL, ON-POLICY

AG-PP0



Memoria
ricorrente LSTM

RL, OFF-POLICY

AG-DQN



Replay buffer
off-policy

LLM, CONTROLLORE


AG-LLM-ACT



L'LLM sceglie
l'azione

LLM, DIMOSTRAZIONI

AG-LLM-GUIDE



Il DQN impara
dall'LLM

LLM, REWARD MODEL

AG-LLM-REW



L'LLM premia
le spinte

PPO e DQN.



AG-PPO
ON-POLICY

Impara dall'esperienza appena raccolta e la utilizza subito, senza conservarla.

- ◆ Gioca otto partite in parallelo per raccogliere più mosse a ogni passo di apprendimento.
- ◆ Una memoria interna gli fa ricordare dove è già passato nello stesso livello.

Scelto come riferimento per la sua stabilità quando i premi sono rari.



AG-DQN
OFF-POLICY

Conserva le partite in un archivio e le riusa molte volte.

- ◆ Riutilizza anche le partite delle fasi precedenti del curriculum, non solo le ultime.
- ◆ Invece di decidere subito la mossa, stima quanto vale ciascuna e poi sceglie.

Sfrutta a fondo poche partite, ma senza memoria del singolo episodio.

Tre punti della pipeline.

Lo stesso modello qwen3, lo stesso chip verde, inserito in tre punti diversi della pipeline.

ollama, qwen3:14b

PROMPT REALE, AG-LLM-ACT

Sokoban: spingi le casse sui target.
muro @ tu \$ cassa . target

. #
\$ #
@ #
#####

Casse su target: 0/1 | Step: 120/120
Rispondi con UNA SOLA parola:
su giu sinistra destra

Mossa: **SU**

il modello sceglie di salire

AG-LLM-ACT

CONTROLLORE

Griglia

→

LLM

→

Azione

Legge lo stato e risponde con una direzione. Zero-shot, nessun addestramento.

AG-LLM-GUIDE

DIMOSTRATORE

LLM

→

Buffer

→

DQN

Gioca alcune partite per fase: riempiono il buffer del DQN. Assente quando l'agente gioca.

AG-LLM-REW

REWARD MODEL

Spinta

→

LLM

→

Premio

Giudica ogni spinta e aggiunge un piccolo premio. Solo $\approx 5\%$ degli step, con cache.

Un LLM locale.

● IN ESECUZIONE LOCALE

qwen3:14b

14B parametri

quantizzato 4-bit

≈ 9 GB VRAM

RTX 4070

via Ollama

primo tentativo: llama3.1:8b → 0% ovunque
collisioni coi muri e risposte malformate, poi scartato

LATENZA PER CHIAMATA

2.3 s → 0.2 s

10×
più veloce

Connessione HTTP persistente

nessuna nuova connessione a ogni chiamata

Contesto ridotto a 512 token

meno memoria occupata, risposta più rapida

Flag think = False


niente catena di ragionamento interna del modello

Due banchi di prova.

10×10

BENCHMARK

DeepMind Boxoban, 4 casse, livelli reali



curriculum

6 fasi, C0-C5


spazio stati

> 10⁸

7×7

OSSERVABILE

generazione procedurale, max 3 casse



curriculum


3 fasi, C0-C2

risolvibilità

BFS esatto C0-C1

Difficoltà crescente.

Si passa alla fase successiva solo quando il solve rate supera una soglia. Se non la raggiunge, la fase si ripete fino a tre volte, e a ogni cambio si riparte dal checkpoint migliore.



10×10

BENCHMARK

soglia avanzamento

da 15% a 2%

budget totale

≈ 9.1M step

7×7

OSSERVABILE

soglia avanzamento

da 50% a 15%


budget totale

≈ 2.1M step

12 RISULTATI, SISTEMA 7×7

Solve rate, una cassa.

Fase C0, 100 episodi per agente.



La memoria vince

PPO ricorrente primo. DQN però risolve in 5.7 mosse contro 22.9.

9% senza training


L'LLM zero-shot eguaglia LLM-REW, poco sotto al DQN addestrato.

13 RISULTATI, SISTEMA 10×10

Una cassa appena scalfita.


Seed 42, 100 episodi per agente. Dataset reale Boxoban.

SOLVE RATE, FASE C0 (UNA CASSA)



DA DUE CASSE IN POI

0%
nessun agente
risolve un livello



220×
meno step del riferimento
≈ 9,1M qui · ≈ 2 miliardi DeepMind (99%)

Quattro letture.

IL RISULTATO MIGLIORE

16%

La memoria conta

PPO ricorrente è il migliore e l'unico oltre lo zero su due casse (fase C1 sistema 7x7)

9%

L'LLM ragiona localmente

Senza training si avvicina al DQN; con think=False non pianifica.

REW

Reward locale, non aiuta

La singola spinta non vede le dipendenze; training $\approx 11\times$ più lento.

GUIDE

Un maestro che non sa

Su Boxoban l'LLM è allo 0%: il buffer si riempie di fallimenti.

Due limiti dichiarati.

RIPRODUCIBILITÀ

Un solo seed

01



Tutti i risultati vengono dal seed 42. Ripetere gli esperimenti su 123 e 456 sarebbe il modo più diretto per confermare la stabilità dei numeri.

BUDGET DI CALCOLO

220× in meno

02



≈ 9M step su una RTX 4070, contro ≈ 2 miliardi su hardware distribuito del riferimento.

In sintesi.

9%

IL RISULTATO CHIAVE

Un LLM senza alcun addestramento RL supera gli agenti addestrati nel posizionare le casse.

Sa ragionare sullo stato attuale; non sa ancora pianificare su più mosse.

DIREZIONI FUTURE

01

Validazione multi-seed su 42, 123 e 456

02

Più budget di calcolo sulle fasi C3-C5

03

Esperimento con think = True

04

Modelli più capaci via API

UNIVERSITÀ DEGLI STUDI DI SALERNO

Grazie.

Reinforcement Learning e Large Language Model
al gioco Sokoban.

Antonio Di Giorgio

Matr. 0522502003, Laurea Magistrale in Informatica

